

한국어 음성 감정 인식에 직접 적용해보기

emotion2vec, ACL 2024



INDEX

목차



목차1

음성 감정 인식과 기존 방식의 한계



목차2

emotion2vec 핵심 원리, teacher-student, online distillation, 두 가지 loss



목차3

논문 검증 결과 freeze + linear만으로 특화모델급 성능



목차4

한국어 감정 분류기 (데이터 · 파이프라인 · 결과)



목차5

논문 주장 vs 한국어 결과, 한계와 개선 방향






Overview

개요


논문 제목	emotion2vec: Self-Supervised Pre-Training for Speech Emotion	사전학습 데이터	라벨 없는 감정 음성 262시간
발표	ACL 2024 (arXiv 2023.12)	학습방식	자기지도 online distillation
저자	Ziyang Ma 외 (Shanghai Jiao Tong Univ. 등)	임베딩 차원	768
분야	음성 감정 인식 (Speech Emotion Recognition)	검증 범위	논문: 영어 + 9개 언어 본 발표: 한국어 직접 적용
핵심모델	emotion2vec (범용 음성 감정 표현 모델)	직접 개발	AI Hub 감정 음성으로 한국어 분류 구현



이 발표는 음성에서 감정을 뽑아내는 범용 표현 모델 emotion2vec을 리뷰하고, 논문의 핵심 주장 (freeze된 표현 위에 linear 분류기만으로 충분하다)이 한국어에서도 성립하는지 직접 구현해 검증한다.

emotion2vec이란

- 음성에서 감정을 뽑아내는 범용 표현 모델
- 라벨 없는 감정 음성 262시간으로 자기지도 학습
- 한 번 학습해두면 감정 인식·노래 감정·대화 감정 예측 등 여러 과제에 사용



모델

입력

음성 (16kHz)

출력

768차원 감정 임베딩

학습데이터

라벨 없는 감정 음성 262시간

학습방식

자기지도 (self-supervised)

핵심특징

하나의 모델로 여러 감정 과제에 범용 적용

두 개의 네트워크 Teacher/Student

Teacher
(채점자)

음성을 온전히 본다 (가리지 않음)

이상적인 정답(목표 표현)을 만들어 제공

직접 학습하지 않음 → 안정적인 기준 역할

VS


Student
(학생)

음성 일부를 가린 채(마스킹) 본다

가려진 부분을 문맥으로 추론해 맞힘

teacher의 표현에 맞추며 스스로 학습

구조는 똑같지만, 보는 방식이 다르다.



emotion2vec

학생은 가려진 구간을 주변 문맥으로 추론한다

음성 파형의 일부 구간을 통째로 가린다


The diagram shows a green audio waveform with two grey rectangular blocks labeled 'masked' covering parts of it. The waveform continues before and after the masked sections.

회색 구간이 가려진 부분 — 학생은 나머지 파형만 보고 이 구간을 추론한다

- 회색 = 가려진 구간, 학생은 못 봄
- 나머지 파형만 보고 추론해 맞힘
- 한 칸씩 X → 여러 칸 연속으로 가림
- 덩어리로 가려야 추론이 일어남

Online Distillation

학생이 좋아지면 채점자도 따라 좋아진다 (EMA)



두 가지 Loss

Frame-level Loss



순간순간의 감정 디테일(문맥 감정)을 학습. 가려진 부분만 예측한다.

Utterance-level Loss



발화 전체의 전반적 감정(글로벌 톤)을 학습. emotion2vec이 data2vec과 갈라지는 지점.

왜 둘 다 필요한가 (ablation)



utterance만: 거의 작동 안 함 / frame만: 쓸 만함 / 둘 다: 최고 성능

결론



세부 디테일(frame) + 전체 톤(utterance)을 합쳐야 감정을 제대로 잡는다. 가중치는 1:1이 최적.

Table 9: Ablation study with different loss.

Frm Loss	Utt Loss	Downstream	WA(%) ↑	UA(%) ↑	WF1(%) ↑
		Utt	28.96	25.0	13.13
		Frm	70.85	71.61	70.71
		Utt	62.77	63.53	62.43
		Frm	71.79	72.69	71.80
		Utt ⊕ Frm	71.37	72.69	71.29

Utterance-level Loss Method In this experiment, we compare the impact of different types of utterance-level loss proposed in Section 3.2 on performance. As shown in Table 10, chunk embedding chosen to compute utterance-level loss performs the best.

평가 방법


방식



freeze + linear

emotion2vec은 학습시키지 않고 그대로 두고(freeze), 위에 linear layer 한 층만 학습한다

이유



왜 일어나

fine-tuning하면 성능이 좋아도 '표현이 좋아서'인지 '후처리가 좋아서'인지 구분이 안 된다. 얼리면 점수 = 표현 품질 그 자체.

의미



무엇을 보는가

"감정 정보가 표현 안에 이미 선형 분리 가능한 형태로 들어있는가"를 직접 측정하는 시험.

같은 크기·더 큰 모델도 이긴다 (IEMOCAP)

IEMOCAP WA(%) 비교

emotion2vec은 같은 base 크기의 SSL 모델을 전부 앞선다. 파라미터가 3배 이상 큰 large 모델보다도 높다. 단순히 모델을 키워서 이긴 게 아니라, 감정에 특화된 표현이라 크기 열세를 뒤집었다.


● WavLM-base : 65.9

● data2vec : 67.4

● data2vec 2.0 : 68.6

● WavLM-large : 70.0

● emotion2vec : 71.8





언어를 넘어 감정을 잡는다

영어 외 9개 언어에서도 SSL 베이스라인 전부 우위


사전학습에 없던 언어에서도 잘 된다.
그런데 논문엔 한국어가 없다.

Political Map of the World, April 2005



언어	데이터셋	emotion2vec 우위
독일어	EmoDB	v
이탈리아어	EMOVO	v
페르시아어	ShEMO	v
우르두어	URDU	v
중국어	M3ED	v

한국어 분류기 직접 개발 후기



목표



논문의 핵심 주장이 한국어에서도 성립할까?

- 논문은 영어와 9개 언어에서 "freeze + linear"만으로 충분하다"를 증명했지만, 한국어는 검증된 적이 없다
- emotion2vec은 freeze, linear 분류기만 학습
- 목표는 높은 성능 자체가 아니라, "한국어에서도 재현되는가"를 직접 확인하는 것




소리에서 감정 특징을 뽑는 부분

- 음성을 넣으면 768차원 감정 임베딩을 출력
- 영어로 학습됐지만 언어와 무관하게 소리 특징을 추출
- 우리는 이 부분을 학습시키지 않고 그대로 사용 (freeze)


임베딩을 한국어 감정으로 판정하는 부분

- emotion2vec이 뽑은 임베딩을 받아 감정 이름표를 붙임 (기쁨·슬픔 등)
- 한국어 데이터로 우리가 직접 학습시키는 유일한 부분
- 구조는 단순한 linear 층 표현이 좋은지 순수하게 시험하기 위함

전체 파이프라인




7감정 → 4감정, 단계적 개선



UA(감정별 평균 정확도)는 불균형 데이터에서 결과를 보는 지표.
7감정에서 4감정으로 줄이자 두 배로 올랐다. 모든 실험은 seed를 고정
해 재현성 확보.

UA 개선 흐름



결과 상세 & 선행연구 비교

개선

class weight로 WA·UA가 균형을 이
룸 → 불균형 해소의 증거

한계

freeze 상태의 천장. 선행연구와 격차
는 방식 차이

방법	WA	UA	WF1
7감정	0.36	0.21	0.31
4감정	0.43	0.35	0.40
4감정 + weight	0.42	0.42	0.41

구분	모델	방식	성능
선행	HuBERT	fine-tune	0.81
본 실험	emotion2vec	freeze	0.42

결과 이유

데이터 불균형

다수 감정으로 쏠림, disgust 0개. class weight로 완화했으나 근본 한계는 남음

Out-of-domain

emotion2vec은 영어 262시간 학습. 한국어는 미검증
→ t-SNE에서 감정이 안 뭉침

원인 분석

Freeze의 한계


표현을 못 바꿔 한국어 운율·억양 반영 안 됨. 선행연구는 fine-tuning으로 표현까지 학습

근거 (시각 자료)

confusion matrix: 소수 감정 오분류 / t-SNE: 감정 군집 흐림

	예측→	angry	happy	neutral	sad		
실제 angry	[	112	60	54	83	]	→ 맞은 건 112, 나머지 197개는 틀림
실제 happy	[	154	273	130	139	]	→ 맞은 건 273
실제 neutral	[	150	184	387	254	]	→ 맞은 건 387
실제 sad	[	107	91	141	329	]	→ 맞은 건 329

emotion2vec embeddings (Korean) - t-SNE



논문의 주장은 한국어에서 성립했나

논문

freeze + linear로 특화모델급 성능

영어 외 9개 언어에서도 일반화 O

"표현만 좋으면 분류는 간단하다"

VS

한국어 (본 실험)

같은 조건인데 UA 0.42에 그침

4감정+개선을 거쳐도 격차 존재

freeze만으로는 한국어를 다 담지 못함

다국어 일반화가 한국어까지 자동 보장되진 않는다



Thank You

감사합니다

"생각보다 어렵고 개발은 힘들었어요"