

한국어 음성 감정 인식에 직접 적용해보기

emotion2vec, ACL 2024



INDEX

목차



목차1

음성 감정 인식과 기존 방식의 한계



목차2

emotion2vec 핵심 원리, teacher-student, online distillation, 두 가지 loss



목차3

논문 검증 결과 freeze + linear만으로 특화모델급 성능



목차4

한국어 감정 분류기 (데이터 · 파이프라인 · 결과)



목차5

논문 주장 vs 한국어 결과, 한계와 개선 방향






Overview

개요


논문 제목	emotion2vec: Self-Supervised Pre-Training for Speech Emotion	사전학습 데이터	라벨 없는 감정 음성 262시간
발표	ACL 2024 (arXiv 2023.12)	학습방식	자기지도 online distillation
저자	Ziyang Ma 외 (Shanghai Jiao Tong Univ. 등)	임베딩 차원	768
분야	음성 감정 인식 (Speech Emotion Recognition)	검증 범위	논문: 영어 + 9개 언어 본 발표: 한국어 직접 적용
핵심모델	emotion2vec (범용 음성 감정 표현 모델)	직접 개발	AI Hub 감정 음성으로 한국어 분류 기 구현



이 발표는 음성에서 감정을 뽑아내는 범용 표현 모델 emotion2vec을 리뷰하고, 논문의 핵심 주장 ("freeze된 표현 위에 linear 분류기만으로 충분하다")이 한국어에서도 성립하는지 직접 구현해 검증한다.

emotion2vec이란

- 음성에서 감정을 뽑아내는 범용 표현 모델.
- 라벨 없는 감정 음성 262시간으로 자기지도 학습
- 한 번 학습해두면 감정 인식·노래 감정·대화 감정 예측 등 여러 과제에 사용



모델

입력

음성 (16kHz)

출력

768차원 감정 임베딩

학습데이터

라벨 없는 감정 음성 262시간

학습방식

자기지도 (self-supervised)

핵심특징

하나의 모델로 여러 감정 과제에 범용 적용

두 개의 네트워크 Teacher/Student

Teacher
(채점자)

음성을 온전히 본다 (가리지 않음)

이상적인 정답(목표 표현)을 만들어 제공

직접 학습하지 않음 → 안정적인 기준 역할

VS

Student
(학생)

음성 일부를 가린 채(마스킹) 본다

가려진 부분을 문맥으로 추론해 맞힘

teacher의 표현에 맞추며 스스로 학습

구조는 똑같지만, 보는 방식이 다르다.



presentation_photo

학생은 가려진 구간을 주변 문맥으로 추론한다




사진에 관한 핵심 설명을 입력해 주세요.

각 프레임이 일정 확률로 마스킹 시작점이 되고, 이후 연속된 여러 프레임을 통째로 가린다. 한 칸만 가리면 바로 옆에서 답을 베낄 수 있어 학습이 너무 쉬워진다. 덩어리로 가려야 진짜 '추론'이 일어난다. 이렇게 가린 부분을 맞히는 과정에서 감정 표현을 스스로 익힌다.

Online Distillation

학생이 좋아지면 채점자도 따라 좋아진다 (EMA)



두 가지 Loss

Frame-level Loss



순간순간의 감정 디테일(문맥 감정)을 학습. 가려진 부분만 예측한다.

Utterance-level Loss



발화 전체의 전반적 감정(글로벌 톤)을 학습. emotion2vec이 data2vec과 갈라지는 지점.

왜 둘 다 필요한가 (ablation)



utterance만: 거의 작동 안 함 / frame만: 쓸 만함 / 둘 다: 최고 성능

결론



세부 디테일(frame) + 전체 톤(utterance)을 합쳐야 감정을 제대로 잡는다. 가중치는 1:1이 최적.

Table 9: Ablation study with different loss.

Frm Loss	Utt Loss	Downstream	WA(%) ↑	UA(%) ↑	WF1(%) ↑
✗	✓	Utt	28.96	25.0	13.13
✓	✗	Frm	70.85	71.61	70.71
✓	✓	Utt	62.77	63.53	62.43
✓	✓	Frm	71.79	72.69	71.80
✓	✓	Utt ⊕ Frm	71.37	72.69	71.29

Utterance-level Loss Method In this experiment, we compare the impact of different types of utterance-level loss proposed in Section 3.2 on performance. As shown in Table 10, chunk embedding chosen to compute utterance-level loss performs the best.



평가 방법

방식



freeze + linear

emotion2vec은 얼리고(학습 안 함), 위
에 linear layer 한 층만 학습한다.
(SUPERB 프로토콜)

이유



왜 얼리나

fine-tuning하면 성능이 좋아도 '표현이 좋
아서'인지 '후처리가 좋아서'인지 구분이 안
된다. 얼리면 점수 = 표현 품질 그 자체.

의미



무엇을 보는가

"감정 정보가 표현 안에 이미 선형 분리 가능
한 형태로 들어있는가"를 직접 측정하는 시
험.

같은 크기·더 큰 모델도 이긴다 (IEMOCAP)

IEMOCAP WA(%) 비교

emotion2vec은 같은 base 크기의 SSL 모델을 전부 앞선다. 파라미터가 3배 이상 큰 large 모델보다도 높다. 단순히 모델을 키워서 이긴 게 아니라, 감정에 특화된 표현이라 크기 열세를 뒤집었다.


● WavLM-base : 65.9

● data2vec : 67.4


● data2vec 2.0 : 68.6

● WavLM-large : 70.0

● emotion2vec : 71.8



언어를 넘어 감정을 잡는다



영어 외 9개 언어에서도 SSL 베이스라인 전부 우위


사전학습에 없던 언어에서도 잘 된다.
그런데 논문엔 한국어가 없다.

언어	데이터셋	emotion2vec 우위
독일어	EmoDB	v
이탈리아어	EMOVO	v
페르시아어	ShEMO	v
우르두어	URDU	v
중국어	M3ED	v


01

한국어 분류기 직접 개발 후기

해당 페이지는 이후 이어질 내용의 타이틀을 적어주는
페이지입니다. 본문 사이사이 들어갈 페이지이므로
문장은 짧고 간결하게 적어주세요.




7감정 → 4감정, 단계적 개선



선 그래프 그리는 법

UA(클래스별 평균 정확도)는 불균형 데이터에서 진짜 실력을 보는 지표. 이 값이 개선을 거치며 0.21 → 0.42로 두 배가 됐다. 모든 실험은 seed 42 고정으로 재현성 확보.

UA 개선 흐름





결과 상세 & 선행연구 비교

개선

class weight로 WA·UA가 균형을 이
룸 → 불균형 해소의 증거

한계

freeze 상태의 천장. 선행연구와 격차
는 방식 차이

방법	WA	UA	WF1
7감정	0.36	0.21	0.31
4감정	0.43	0.35	0.40
4감정 + weight	0.42	0.42	0.41

구분	모델	방식	성능
선행	HuBERT	fine-tune	0.81
본 실험	emotion2vec	freeze	0.42

결과 이유

데이터 불균형

다수 감정으로 쏠림, disgust 0개. class weight로 완화했으나 근본 한계는 남음

Out-of-domain

emotion2vec은 영어 262시간 학습. 한국어는 미검증
→ t-SNE에서 감정이 안 뭉침

원인 분석

Freeze의 한계

표현을 못 바꿔 한국어 운율·억양 반영 안 됨. 선행연구는 fine-tuning으로 표현까지 학습

근거 (시각 자료)

confusion matrix: 소수 감정 오분류 / t-SNE: 감정 군집 흐림

논문의 주장은 한국어에서 성립했나

논문

freeze + linear로 특화모델급 성능

영어 외 9개 언어에서도 일반화 O

"표현만 좋으면 분류는 간단하다"

VS

한국어 (본 실험)

같은 조건인데 UA 0.42에 그침

4감정+개선을 거쳐도 격차 존재

freeze만으로는 한국어를 다 담지 못함

다국어 일반화가 한국어까지 자동 보장되진 않는다

한계와 개선 방향



Fine-tuning

emotion2vec을 얼리지 않고 한국어로 학습 → 표현 자체를 한국어에 맞춤 (가장 효과 클 것)

한국어 감정 데이터로 emotion2vec
재사전학습, out-of-domain 해소

추가 사전학습



데이터 보강

소수 감정 데이터 확충으로 불균형 근본 대응

결론

발견



논문은 freeze+linear로 특화모델급,
9개 언어 일반화. 한국어는 같은 조건인
데 재현 안 됨
다국어 일반화가 한국어까지 자동 보장
되진 않는다.

원인



emotion2vec은 영어 262시간 사전
학습. 한국어는 out-of-domain이라
표현 단계에서 감정이 잘 분리되지 않았
다.

개선



7감정 → 4감정 → class weight로
UA 0.21 → 0.42 개선. 다음은 fine-
tuning·한국어 추가 사전학습으로 표현
자체를 한국어에 맞추는 것.

배운점



좋은 표현이 절반, 도메인 적합성이 나
머지 절반. 데이터부터 임베딩·학습·분
석까지 파이프라인을 끝까지 직접 돌려
봤다.





Thank You

감사합니다

여백을 충분히 두어 시선이 오직 텍스트에만 집중되도록 하세요.

"백 마디 말보다 잘 고른 한 장의 문장이 더 강력한 메시지를 전달한다."